Insurance Premium-Copy1

September 4, 2023

Cissé NIANG

Prédiction du coût de l'assurance médicale

[51]:
```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from scipy.stats import kurtosis, skew, stats
from sklearn.linear_model import LinearRegression
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import accuracy_score
from sklearn.metrics import mean_absolute_error, mean_squared_error,r2_score
from sklearn.preprocessing import LabelEncoder
from sklearn import linear_model
from sklearn.feature_selection import SelectKBest
from sklearn.feature_selection import f_regression
from sklearn.preprocessing import PolynomialFeatures
import warnings
warnings.filterwarnings("ignore")
```

[2]:
```
df=pd.read_csv('/Users/cisseniang/Documents/Data/Données ML/Insurance.csv')
```

[3]:
```
df.head()
```

[3]:

	age	sex	bmi	children	smoker	region	expenses
0	19	female	27.9	0	yes	southwest	16884.92
1	18	male	33.8	1	no	southeast	1725.55
2	28	male	33.0	3	no	southeast	4449.46
3	33	male	22.7	0	no	northwest	21984.47
4	32	male	28.9	0	no	northwest	3866.86

[4]:
```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1338 entries, 0 to 1337
Data columns (total 7 columns):
 #   Column    Non-Null Count  Dtype
---  ------    --------------  -----
```

```
 0   age       1338 non-null   int64
 1   sex       1338 non-null   object
 2   bmi       1338 non-null   float64
 3   children  1338 non-null   int64
 4   smoker    1338 non-null   object
 5   region    1338 non-null   object
 6   expenses  1338 non-null   float64
dtypes: float64(2), int64(2), object(3)
memory usage: 73.3+ KB
```

0.1 Vérifier les données manquantes

[5]:
```
(df.isnull().sum()/df.shape[0]).sort_values(ascending = False)
```

[5]:
```
age         0.0
sex         0.0
bmi         0.0
children    0.0
smoker      0.0
region      0.0
expenses    0.0
dtype: float64
```

0.2 Visualisations et statistiques descriptives des données

[6]:
```
f, axes = plt.subplots(1, 2)
plt.figure(figsize=(16,8))
sns.boxplot(df['bmi'], ax=axes[0])
sns.boxplot(df['age'], ax=axes[1])
plt.show()
```

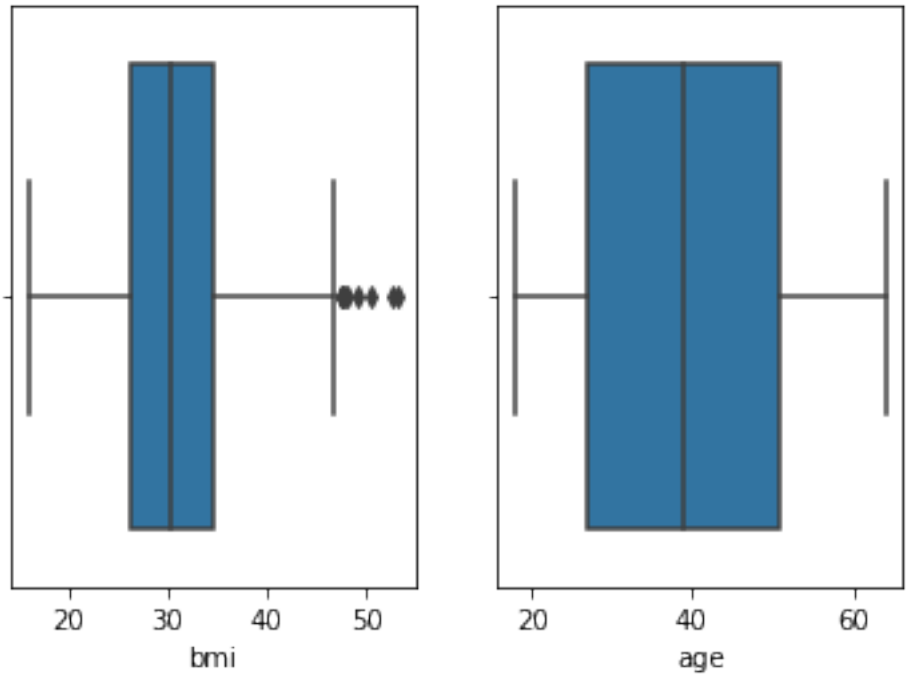


```
<Figure size 1152x576 with 0 Axes>
```

[7]:
```
f, axes = plt.subplots(1, 2)
sns.boxplot(df['expenses'], ax=axes[0])
sns.kdeplot(df['expenses'], ax=axes[1])
plt.show()
```

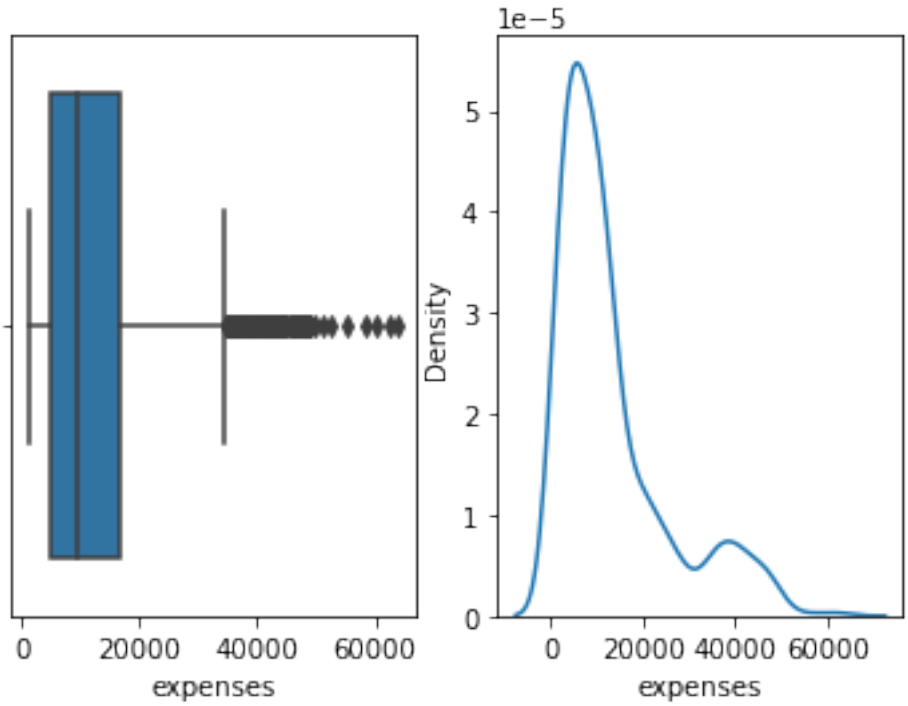

Le diagramme de la densité nous montre que les données relatives aux charges (expenses) sont asymétriques à droite, de même que le diagramme en boite nous montre que La distribution est positivement asymétrique, car la portion droite de la boîte et la moustache droite sont plus longues qu'à gauche de la médiane

[8]:
```
df[['age', 'bmi', 'expenses']].describe().T
```

[8]:

	count	mean	std	min	25%	50%	\
age	1338.0	39.207025	14.049960	18.00	27.0000	39.00	
bmi	1338.0	30.665471	6.098382	16.00	26.3000	30.40	
expenses	1338.0	13270.422414	12110.011240	1121.87	4740.2875	9382.03	

	75%	max
age	51.000	64.00
bmi	34.700	53.10
expenses	16639.915	63770.43

Pour explorer le comportement de certianes variables par rapport aux autres, nous allons recourir à d'autres indicateurs statistiques tels que la matrice de corrélation et la matrice de covariance.

En effet, la matrice de covariance mesure la covariation entre deux variables aléatoires. Elle donne une idée de la manière dont les variables évoluent conjointement. Si la covariance est positive, cela signifie que les deux variables tendent à augmenter ensemble, tandis qu'une covariance négative indique que lorsque l'une des variables augmente, l'autre tend à diminuer. Une covariance nulle signifie qu'il n'y a pas de relation linéaire entre les variables.

```
Cov(X, Y) = Σ[(xi - x) * (yi - y)] / (n - 1)
```

[9]:
```
df.cov()
```

[9]:

	age	bmi	children	expenses
age	197.401387	9.368560	0.719303	5.087480e+04
bmi	9.368560	37.190265	0.092958	1.466515e+04
children	0.719303	0.092958	1.453213	9.926742e+02
expenses	50874.802133	14665.149703	992.674243	1.466524e+08

La matrice de corrélation est une version normalisée de la matrice de covariance. Elle mesure la force et la direction de la relation linéaire entre deux variables, tout en éliminant l'effet de l'échelle. La corrélation est comprise entre -1 et 1. Une corrélation de 1 indique une relation linéaire positive parfaite, -1 indique une relation linéaire négative parfaite, et 0 indique aucune corrélation linéaire.

```
Corr(X, Y) = Cov(X, Y) / ( x * y)
```

[10]:
```
df.corr()
```

[10]:

	age	bmi	children	expenses
age	1.000000	0.109341	0.042469	0.299008
bmi	0.109341	1.000000	0.012645	0.198576
children	0.042469	0.012645	1.000000	0.067998
expenses	0.299008	0.198576	0.067998	1.000000

[11]:
```
plt.figure(figsize=(8,6))
ax = sns.heatmap(df.corr(),vmin=-1,vmax=1,center=0,annot=True)
```

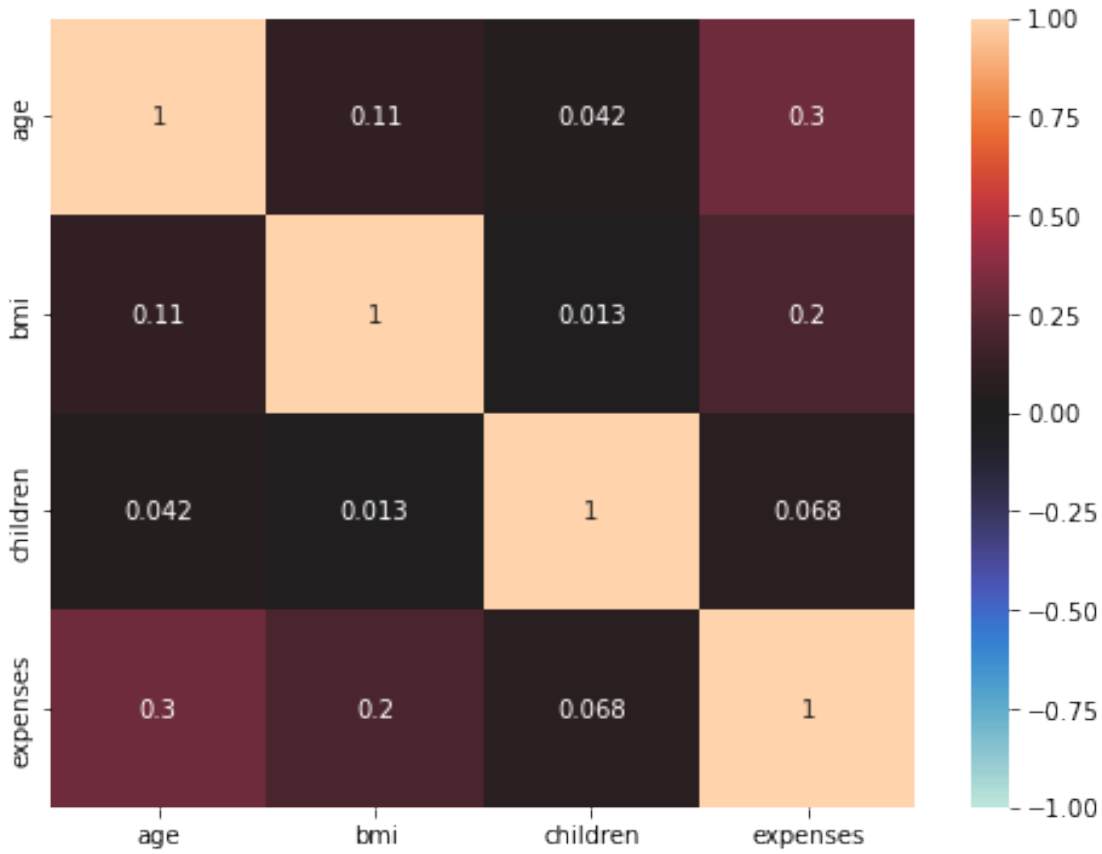

Cette matrice de corrélation nous montre que :
1- il y a une corrélation faible entre l'âge et l'indice de masse corporelle (bmi), une corrélation encore plus faible avec le nombre d'enfants (children), et une corrélation modérée avec les dépenses médicales (expenses). La corrélation positive avec les dépenses médicales suggère que les personnes plus âgées ont tendance à avoir des dépenses médicales plus élevées.

2-L'indice de masse corporelle (BMI) présente une corrélation faible avec l'âge, une corrélation très faible avec le nombre d'enfants (children), et une corrélation modérée avec les dépenses médicales (expenses). Cela suggère que des niveaux élevés d'IMC ne sont que modérément associés à des dépenses médicales plus élevées.

3-Le nombre d'enfants (children) présente une corrélation faible avec l'âge, une corrélation très faible avec l'indice de masse corporelle (bmi), et une corrélation faible avec les dépenses médicales (expenses). Cela suggère que le nombre d'enfants a un impact limité sur les dépenses médicales.

4-Les dépenses médicales (expenses) présentent une corrélation modérée avec l'âge, une corrélation modérée avec l'indice de masse corporelle (bmi), et une corrélation faible avec le nombre d'enfants (children). Cela suggère que l'âge et l'indice de masse corporelle sont des facteurs plus importants dans la détermination des dépenses médicales que le nombre d'enfants.

[12]:
```
sns.countplot(x='sex', data=df)
```

[12]: <AxesSubplot:xlabel='sex', ylabel='count'>

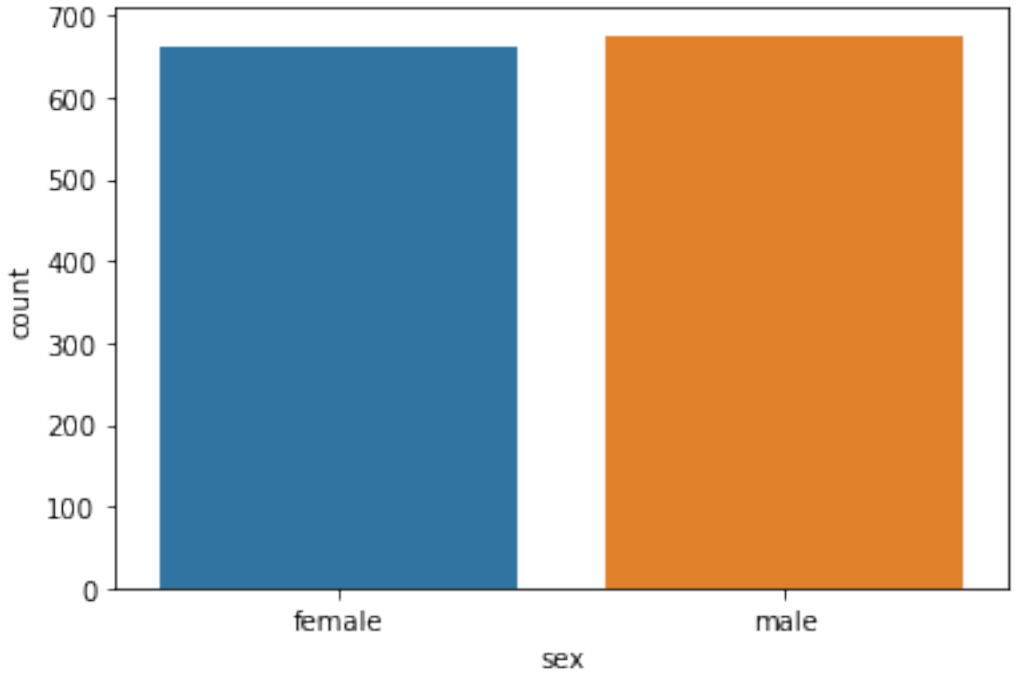

[13]:
```
df.children.value_counts(normalize=True)*100
```

[13]:
```
0    42.899851
1    24.215247
2    17.937220
3    11.733931
4     1.868460
5     1.345291
Name: children, dtype: float64
```

[14]:
```
plt.figure(figsize=(8,8))

df.children.value_counts().plot(kind='pie',autopct='%1.1f%%')
plt.title('children',fontsize='15')
centre_circle = plt.Circle((0, 0), 0.70, fc='white')
fig = plt.gcf()
fig.gca().add_artist(centre_circle)
```

[14]: <matplotlib.patches.Circle at 0x7f941afff8b0>

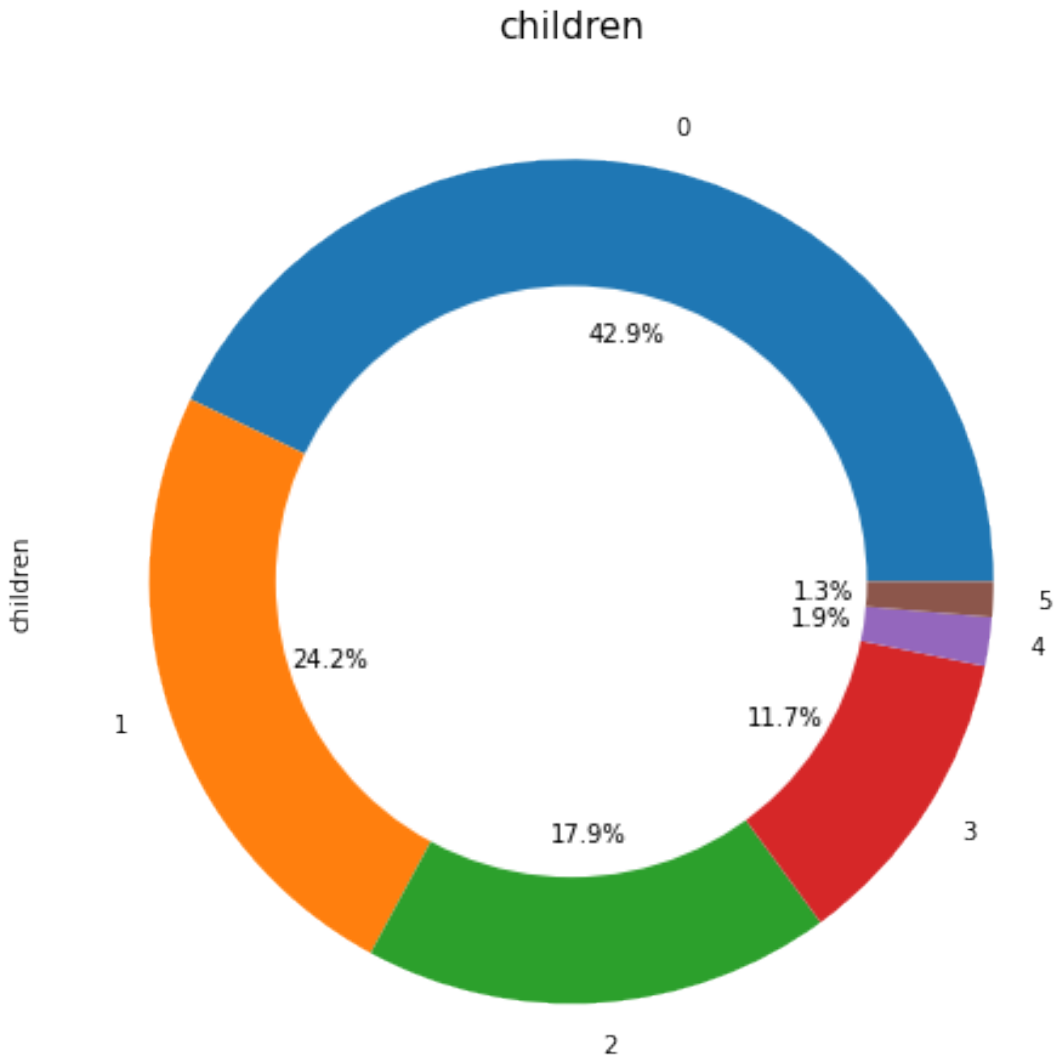

[15]:
```
df.region.value_counts(normalize=True)*100
```

[15]:
```
southeast    27.204783
southwest    24.289985
northwest    24.289985
northeast    24.215247
Name: region, dtype: float64
```

[16]:
```
plt.figure(figsize=(8,8))

df.region.value_counts().plot(kind='pie',autopct='%1.1f%%')
plt.title('Région',fontsize='15')
```

```
centre_circle = plt.Circle((0, 0), 0.70, fc='white')
fig = plt.gcf()
fig.gca().add_artist(centre_circle)
```

[16]: <matplotlib.patches.Circle at 0x7f94091edbb0>

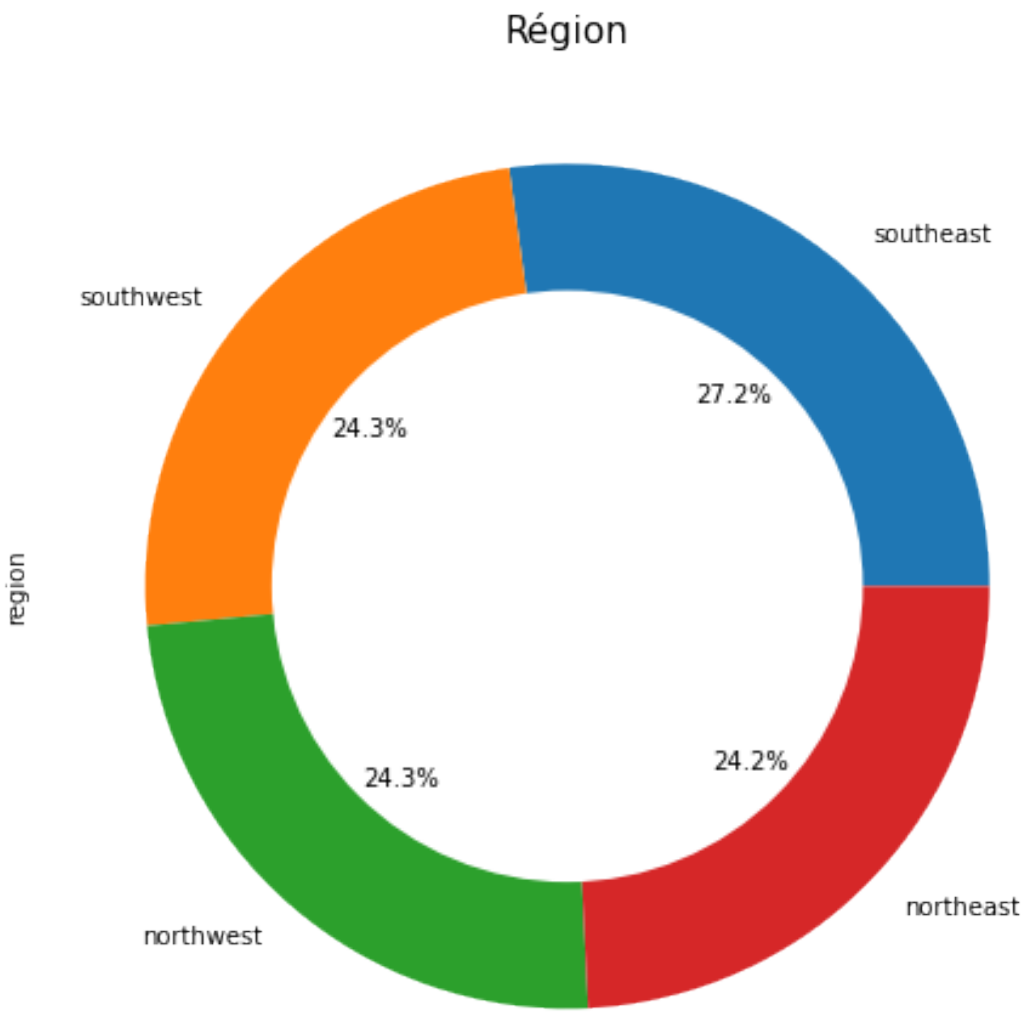

[17]:
```
plt.figure(figsize=(8,8))

df.smoker.value_counts().plot(kind='pie',autopct='%1.1f%%')
plt.title('smoker',fontsize='15')
centre_circle = plt.Circle((0, 0), 0.70, fc='white')
fig = plt.gcf()
```

```
fig.gca().add_artist(centre_circle)
```

[17]: <matplotlib.patches.Circle at 0x7f93f9184280>

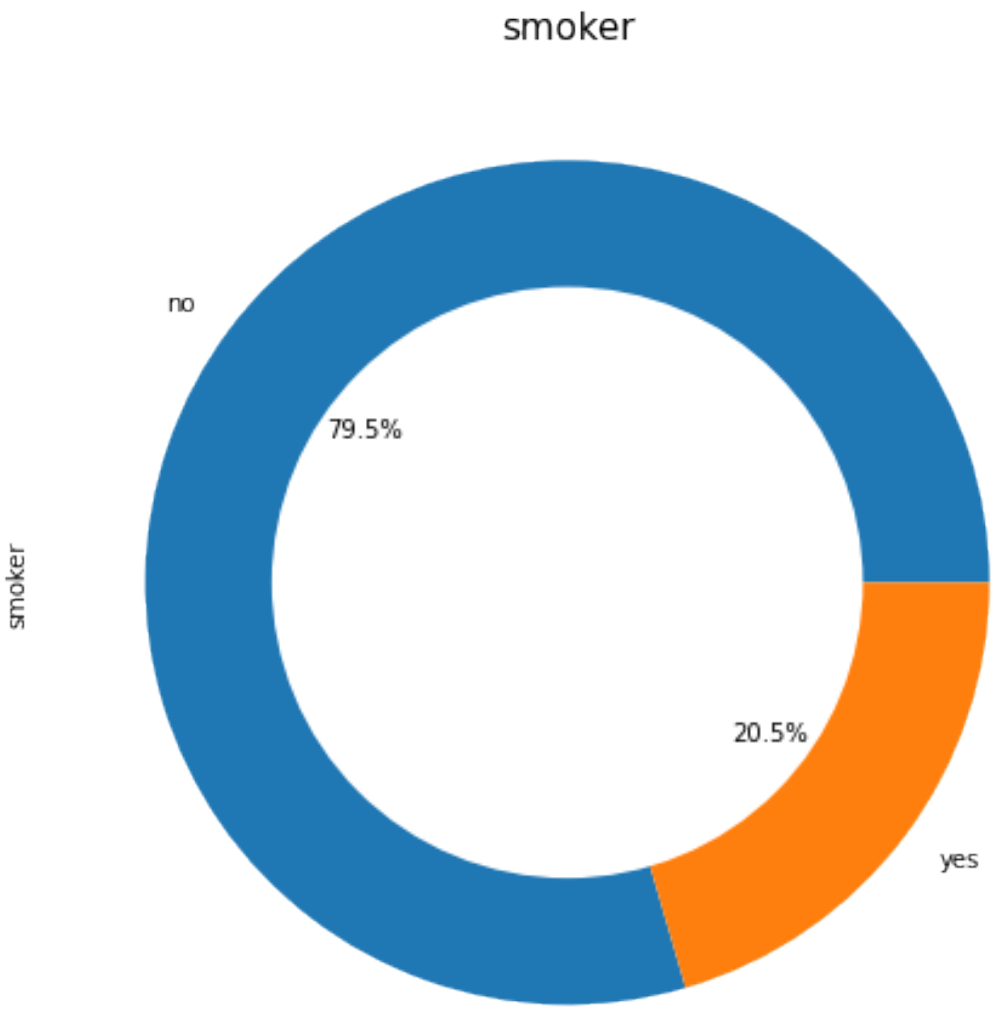

[18]:
```
df.groupby("smoker").expenses.agg(["mean","median","count"])
```

[18]:

smoker	mean	median	count
no	8434.268449	7345.405	1064
yes	32050.231971	34456.350	274

[19]:
```
#df['smoker'].value_counts(normalize=True)*100
df['smoker'].value_counts()/df.shape[0]*100
```

[19]:
```
no     79.521674
yes    20.478326
Name: smoker, dtype: float64
```

[20]:
```
df.duplicated().sum()
```

[20]:
```
1
```

[21]:
```
df = df.drop_duplicates()
```

[22]:
```
df.duplicated().sum()
```

[22]:
```
0
```

Détection des valeurs aberrantes :

Pour élimier les valeurs aberrantes, nous utilisons la technique selon laquelle :

```
Valeur < Q1-1.5*IQR ou Valeur > Q3+1.5*IQR

IQR = Q3-Q1
```

[23]:
```
## définir une fonction de détection des valeurs aberrantes

def outlier_detect(df, variable_name):
    IQR = df[variable_name].quantile(0.75) - df[variable_name].quantile(0.25)
    lower = df[variable_name].quantile(0.25) - 1.5*IQR
    upper = df[variable_name].quantile(0.75) + 1.5*IQR
    return df[(df[variable_name]<lower) | (df[variable_name]>upper)]
```

[24]:
```
outlier_detect(df, 'expenses').sort_values('expenses')
```

[24]:

	age	sex	bmi	children	smoker	region	expenses
623	18	male	33.5	0	yes	northeast	34617.84
1078	28	male	31.7	0	yes	southeast	34672.15
223	19	male	34.8	0	yes	southwest	34779.62
689	27	male	31.1	1	yes	southeast	34806.47
1291	19	male	34.9	0	yes	southwest	34828.65
…	…	…	…	…	…	…	…
819	33	female	35.5	0	yes	northwest	55135.40
577	31	female	38.1	1	yes	northeast	58571.07
1230	52	male	34.5	3	yes	northwest	60021.40
1300	45	male	30.4	0	yes	southeast	62592.87
543	54	female	47.4	0	yes	southeast	63770.43

[139 rows x 7 columns]

[25]:
```
outlier_detect(df,'bmi').sort_values('bmi')
```

[25]:

	age	sex	bmi	children	smoker	region	expenses
543	54	female	47.4	0	yes	southeast	63770.43
401	47	male	47.5	1	no	southeast	8083.92
860	37	female	47.6	2	yes	southwest	46113.51
1088	52	male	47.7	1	no	southeast	9748.91
286	46	female	48.1	2	no	northeast	9432.93
116	58	male	49.1	0	no	southeast	11381.33
847	23	male	50.4	1	no	southeast	2438.06
1047	22	male	52.6	1	yes	southeast	44501.40
1317	18	male	53.1	0	no	southeast	1163.46

Remplaçons les valeurs aberrantes de la borne inférieure par Q1-1.5*IQR et celles de la borne supérieure par Q3+1.5*IQR

[26]:
```
df['expenses'].quantile(0.75)+1.5*(df['expenses'].quantile(0.75)-df['expenses'].
↪quantile(0.25))
```

[26]: 34524.79

[27]:
```
df.loc[(outlier_detect(df,'expenses').index, 'expenses')] =df['expenses'].
↪quantile(0.75)+1.5*(df['expenses'].quantile(0.75)-
                                                                                ␣
↪              df['expenses'].quantile(0.25))
```

[28]:
```
f, axes = plt.subplots(1, 2)
sns.boxplot(df['expenses'], ax=axes[0])
sns.kdeplot(df['expenses'], ax=axes[1])
plt.show()
```

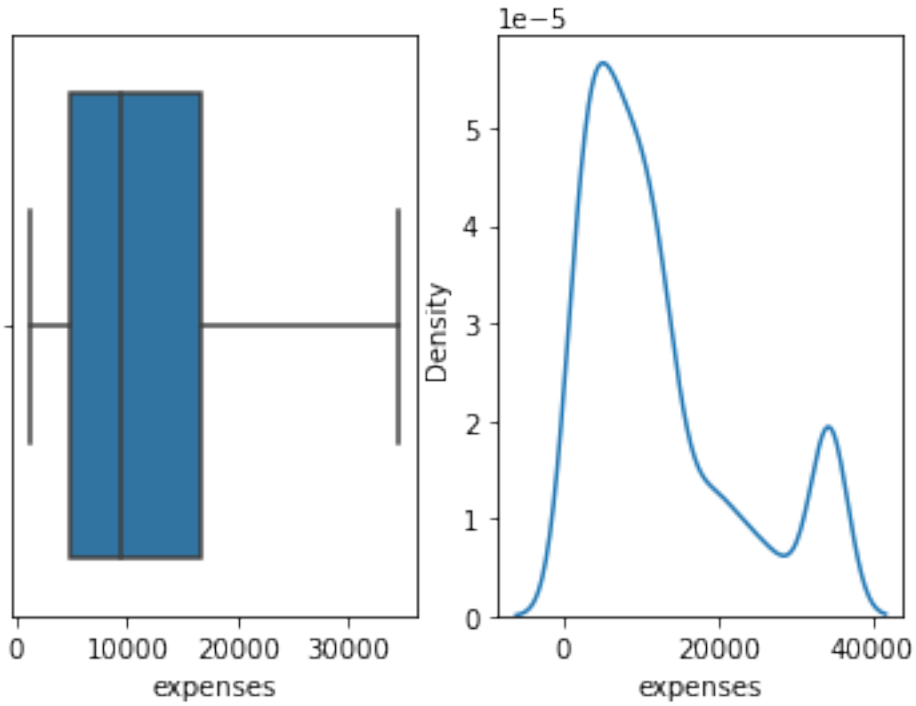

[29]:
```
df.loc[(outlier_detect(df,'bmi').index, 'bmi')] =df['bmi'].quantile(0.75)+1.
↪5*(df['bmi'].quantile(0.75)-

↪              df['bmi'].quantile(0.25))
```

[30]:
```
plt.figure(figsize=(5,5))
sns.boxplot(df['bmi'])
plt.show()
```

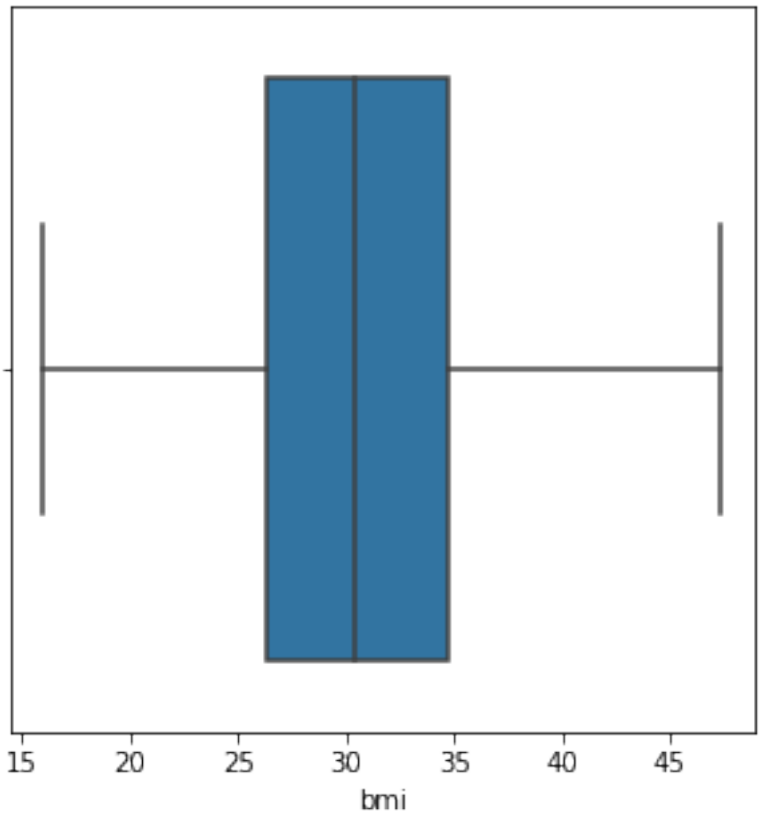

0.3 Préparations des données

Séparer les variables catégorielles et numériques

[31]:
```
#Séparer les variables catégorielles et numériques

cat_df =[]
num_df = []
for j, i in enumerate(df.dtypes):
    if i == object:
        cat_df.append(df.iloc[:,j])
    else :
        num_df.append(df.iloc[:,j])
```

[32]:
```
cat_df = pd.DataFrame(cat_df).transpose()
num_df = pd.DataFrame(num_df).transpose()
```

[33]:
```
cat_df.head()
```

[33]:

	sex	smoker	region
0	female	yes	southwest
1	male	no	southeast

```
2    male     no  southeast
3    male     no  northwest
4    male     no  northwest
```

[34]:
```
num_df.head()
```

[34]:
```
     age   bmi  children  expenses
0  19.0  27.9       0.0  16884.92
1  18.0  33.8       1.0   1725.55
2  28.0  33.0       3.0   4449.46
3  33.0  22.7       0.0  21984.47
4  32.0  28.9       0.0   3866.86
```

[35]:
```
num_df['children'] = num_df['children'].astype(int)
num_df['age'] = num_df['age'].astype(int)
```

transformations des variables categorielles en variables dichotommiques

[36]:
```
#transformations des variables categorielles en variables dichotommiques
labelencoder = LabelEncoder()

for i in cat_df:
    cat_df[i] = labelencoder.fit_transform(cat_df[i])
cat_df
```

[36]:
```
       sex  smoker  region
0        0       1       3
1        1       0       2
2        1       0       2
3        1       0       1
4        1       0       1
…    …      …       …
1333     1       0       1
1334     0       0       0
1335     0       0       2
1336     0       0       3
1337     0       1       1

[1337 rows x 3 columns]
```

[37]:
```
cat_df['sex'].nunique()
```

[37]:
```
2
```

[38]:
```
cat_df['smoker'].nunique()
```

[38]:
```
2
```

[39]:
```
cat_df['region'].nunique()
```

[39]: 4

[40]:
```
data = pd.concat([num_df, cat_df], axis =1)
```

[41]:
```
data.head()
```

[41]:

	age	bmi	children	expenses	sex	smoker	region
0	19	27.9	0	16884.92	0	1	3
1	18	33.8	1	1725.55	1	0	2
2	28	33.0	3	4449.46	1	0	2
3	33	22.7	0	21984.47	1	0	1
4	32	28.9	0	3866.86	1	0	1

[42]:
```
X = data.drop('expenses', axis=1)
y = data['expenses']


X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.2,␣
↪random_state = 123)

X_val, X_test, y_val, y_test = train_test_split(X_test, y_test, test_size = 0.
↪2, random_state = 123)
```

[43]:
```
X.shape
```

[43]: (1337, 6)

[44]:
```
y.shape
```

[44]: (1337,)

0.4 Modélisations

0.4.1 Modèle de régression linéaire

[45]:
```
model_reg = LinearRegression()

model_reg.fit(X_train, y_train)
model_reg.score(X_train, y_train)
#model.predict(X_train)

print(model_reg.intercept_)

print(model_reg.coef_)

print(model_reg.score(X_test, y_test))
```

```
-6949.413155648976
[  233.19251789   210.29765071   462.41384768  -164.0645531
 19723.08258238  -355.18699393]
0.8133343561896759
```

0.4.2 Modèle de Ridge Regression

[46]:
```
model_ridge = linear_model.Ridge(alpha=.5)

model_ridge.fit(X_train, y_train)
model_ridge.score(X_train, y_train)
#model.predict(X_train)

print(model_ridge.intercept_)

print(model_ridge.coef_)

print(model_ridge.score(X_test, y_test))
```

```
-6938.418261357763
[  233.15278515   210.31589157   461.85220107  -159.58724772
 19666.42466037  -355.13765316]
0.8134101609303416
```

0.4.3 Modèle de Lasso Regression

[47]:
```
model_lasso = linear_model.Ridge(alpha=.1)

model_lasso.fit(X_train, y_train)
model_lasso.score(X_train, y_train)
#model.predict(X_train)

print(model_lasso.intercept_)

print(model_lasso.coef_)

print(model_lasso.score(X_test, y_test))
```

```
-6947.209538455327
[  233.18455343   210.30130451   462.30128025  -163.1658135
 19711.72476242  -355.17717729]
0.813350459813973
```

[53]:
```
# Utilisez SelectKBest avec le test ANOVA pour sélectionner les K meilleures␣
↪caractéristiques
k_best = SelectKBest(score_func=f_regression, k=4)  # Choisissez le nombre de␣
↪caractéristiques souhaité (ici, 4)
```

```
# Appliquez la sélection des caractéristiques aux données
X_new = k_best.fit_transform(X, y)

# on peut maintenant accéder aux caractéristiques sélectionnées
selected_features = X.columns[k_best.get_support()]

# Affichez les caractéristiques sélectionnées
print("Caractéristiques sélectionnées :")
print(selected_features)
```

```
Caractéristiques sélectionnées :
Index(['age', 'bmi', 'children', 'smoker'], dtype='object')
```

[56]:
```
X = data.drop(['expenses', 'sex', 'region'], axis = 1)
y = data.expenses
pol = PolynomialFeatures (degree = 2)
X_pol = pol.fit_transform(X)
X_train, X_test, y_train, y_test = train_test_split(X_pol, y, test_size=0.2,␣
 ↪random_state=123)
Pol_reg = LinearRegression()
Pol_reg.fit(X_train, y_train)
y_train_pred = Pol_reg.predict(X_train)
y_test_pred = Pol_reg.predict(X_test)
print(Pol_reg.intercept_)
print(Pol_reg.coef_)
print(Pol_reg.score(X_test, y_test))
```

```
-10664.563532045735
[   0.           21.11708516  781.22184512 1707.32239821 -671.31759102
    4.04466494   -2.51149326   -3.24261403 -139.59000629  -10.83660297
   -4.06409661  882.69878207 -216.33924321 -608.24549705 -671.31759102]
0.8759348704836983
```

[57]:
```
## the best model
```

[59]:
```
##Prédire les dépenses sur le meilleur modèle
y_test_pred = Pol_reg.predict(X_test)

df = pd.DataFrame({'Actual': y_test, 'Predicted': y_test_pred})
df
```

[59]:

	Actual	Predicted
28	2775.19	2613.715521
547	11538.42	10605.638341
857	15817.99	19852.198903
1336	2007.95	3144.112651
221	10564.88	11381.658129
…	…	…

```
186    3981.98   6474.379989
867   11576.13  11997.743603
67     6389.38   8314.450346
631    1977.82   3992.576237
1225   4795.66   6287.587869

[268 rows x 2 columns]
```

[ ]: